

Projet Python pour la Data

Synthèse des conclusions — Sujets 1, 2 et 3

INSI — Institut National Supérieur d'Informatique | Groupe 1 L1D

N°	Nom et Prénom	Matricule
1	HARIMINO Faly Henintsoa	401
2	ANDRIAMIRADO Fanomezantsoa Fiononana	402

Ce document rassemble, pour chacun des trois sujets obligatoires du projet, la problématique traitée et les conclusions issues de l'analyse des données réalisée avec NumPy et Pandas. Le détail des traitements (nettoyage, transformations, calculs) figure dans les notebooks associés (*sujet_01_titanic.ipynb*, *sujet_02_supermarket.ipynb*, *sujet_03_videogames.ipynb*).

Sujet 1 — Analyse des passagers du Titanic

Dataset : Titanic - Machine Learning from Disaster (Kaggle, train.csv, 891 passagers)

Problématique : Identifier les principaux facteurs associés à la survie des passagers du Titanic, sans développer de modèle de Machine Learning.

Conclusions

- Le sexe est le facteur de survie le plus déterminant :** les femmes ont un taux de survie très largement supérieur à celui des hommes, conformément à la règle « les femmes et les enfants d'abord ».
- La classe sociale a fortement influencé la survie :** les passagers de 1^{re} classe ont survécu dans une bien plus grande proportion que ceux de 3^e classe, probablement en raison de la proximité des cabines avec les canots de sauvetage.
- L'effet cumulé sexe + classe est majeur :** les femmes de 1^{re} classe affichent le taux de survie le plus élevé du dataset, tandis que les hommes de 3^e classe affichent le taux le plus faible.
- Les enfants ont été globalement favorisés** par rapport aux adultes dans la répartition des taux de survie par groupe d'âge.
- La composition familiale joue un rôle intermédiaire :** voyager en petite famille est associé à un meilleur taux de survie que voyager complètement seul.
- Le prix du billet corrèle avec la survie**, car il reflète indirectement la classe et donc l'accès prioritaire à l'évacuation.
- Profil le plus favorisé :** femme voyageant en 1^{re}/2^e classe, en famille restreinte. **Profil le moins favorisé :** homme adulte de 3^e classe voyageant seul.

Sujet 2 — Analyse des ventes d'un supermarché

Dataset : Supermarket Sales (Kaggle, 1000 transactions, 3 agences : Yangon, Naypyitaw, Mandalay)

Problématique : Analyser les transactions d'une chaîne de supermarchés afin de mieux comprendre ses ventes, ses clients et les performances de ses différentes agences.

Conclusions

- 1 **Les trois agences sont globalement équilibrées en volume** mais présentent des écarts de chiffre d'affaires et de satisfaction client (Rating) qui justifient un suivi individualisé.
- 2 **Le CA calculé (Prix unitaire × Quantité) est systématiquement inférieur au Total** d'un montant correspondant exactement à la taxe de 5%, ce qui confirme la cohérence du dataset.
- 3 **Certaines catégories de produits génèrent disproportionnellement plus de chiffre d'affaires** que d'autres : il est recommandé de renforcer les catégories les plus performantes et d'investiguer les causes de sous-performance des autres.
- 4 **Les clients « Member » et « Normal » ont des comportements d'achat différents** : un programme de fidélité ciblé sur les clients « Normal » à fort potentiel pourrait augmenter le taux de conversion.
- 5 **La satisfaction client ne suit pas nécessairement le chiffre d'affaires** : une agence ou une catégorie peut générer beaucoup de revenus avec une satisfaction perfectible, un risque à surveiller pour la fidélisation à moyen terme.
- 6 **La répartition des dépenses entre hommes et femmes est proche mais pas identique**, ce qui peut orienter des campagnes marketing différenciées selon les catégories de produits privilégiées par chaque segment.

Sujet 3 — Analyse mondiale des jeux vidéo

Dataset : Video Game Sales / vgsales.csv (Kaggle, 16 598 jeux, ventes par zone géographique)

Problématique : Comprendre les tendances historiques du marché mondial du jeu vidéo : évolution dans le temps, poids des zones géographiques, plateformes et éditeurs dominants.

Conclusions

- 1 **Un très petit nombre de jeux « phénomènes » concentre une part importante des ventes mondiales**, révélant un marché où le succès est fortement concentré sur quelques licences majeures.
- 2 **Nintendo et ses plateformes dominent historiquement le classement**, en particulier sur le marché japonais, traduisant une stratégie de plateformes propriétaires très efficace sur le long terme.
- 3 **L'Amérique du Nord reste la plus grande zone de vente en volume**, suivie de l'Europe, tandis que le Japon constitue un marché plus petit mais avec des préférences de genres et de plateformes très spécifiques.
- 4 **Le marché a connu un pic d'activité durant les années 2000**, porté par l'essor des consoles de salon et portables de l'époque, avant un ralentissement du nombre de titres physiques recensés sur la dernière décennie du dataset.
- 5 **La comparaison par période (avant 2000 / 2000-2009 / 2010 et après) montre une croissance puis une stabilisation ou un recul** du nombre de sorties et des ventes totales, cohérente avec la transition du marché vers le numérique, moins bien capturée par ce type de dataset orienté ventes physiques.
- 6 **Les genres Action et Sports figurent parmi les catégories les plus vendues mondialement**, alors que leur popularité relative varie sensiblement d'une zone géographique à l'autre, confirmant l'intérêt d'une stratégie commerciale différenciée par région.