

Présentation orale — Projet Python pour la Data

Groupe 1 L1D — INSI

Durée indicative totale : 8 à 10 minutes (≈ 2 min par partie)

Introduction (à lire en ouverture, avant la Partie 1)

Bonjour à tous. Nous allons vous présenter notre projet pratique de Python pour la Data, réalisé avec NumPy et Pandas uniquement, sans aucun modèle de Machine Learning.

Notre mission a été de nous mettre dans la peau de Data Analysts sur trois jeux de données réels issus de Kaggle : le **Titanic**, pour identifier les facteurs de survie des passagers ; les **ventes d'un supermarché**, pour analyser la performance commerciale de trois agences ; et le marché mondial du **jeu vidéo**, pour comprendre ses tendances historiques.

Pour chacun de ces trois sujets, nous avons suivi la même démarche en quatre grandes étapes : l'exploration des données, leur nettoyage, la création de nouvelles variables et les premières analyses, puis les analyses plus avancées débouchant sur nos conclusions. C'est cette structure en quatre parties que nous allons suivre pour la présentation.

Partie 1 — Exploration et qualité des données

Avant d'analyser quoi que ce soit, il faut comprendre ce que l'on a entre les mains. Pour chacun des trois datasets, nous avons commencé par un travail d'exploration systématique.

Nous avons chargé les fichiers avec Pandas, affiché un échantillon des données, vérifié les dimensions — nombre de lignes et de colonnes — ainsi que les types de chaque variable. Nous avons ensuite utilisé les fonctions `info()` et `describe()` pour obtenir une vue d'ensemble statistique : moyennes, valeurs minimales et maximales, répartition des catégories.

Cette étape nous a surtout permis d'identifier les problèmes de qualité des données. Sur le Titanic, nous avons repéré des valeurs manquantes importantes sur l'âge, la cabine et le port d'embarquement. Sur les ventes du supermarché, le dataset s'est révélé complet, sans valeur manquante ni doublon. Et sur les jeux vidéo, nous avons identifié des années de sortie et des éditeurs manquants sur une partie des lignes.

Cette phase d'exploration est essentielle : c'est elle qui a orienté toutes les décisions de nettoyage que nous allons vous présenter maintenant.

Partie 2 — Nettoyage et préparation des données

Une fois les problèmes identifiés, il a fallu les traiter, en justifiant chaque choix plutôt qu'en appliquant une méthode automatique.

Pour le **Titanic**, l'âge manquant a été complété par la médiane calculée par sous-groupe de sexe et de classe, plus représentative qu'une moyenne globale. La colonne cabine, incomplète à plus de 75 %, n'a pas été imputée mais transformée en indicateur exploitable. Le port d'embarquement,

avec seulement deux valeurs manquantes, a été complété par le mode.

Pour les **ventes du supermarché**, le travail a surtout porté sur la préparation : conversion de la date en format exploitable, création de colonnes jour, mois et jour de la semaine, et calcul d'un chiffre d'affaires que nous avons comparé à la colonne Total du dataset — l'écart s'expliquant simplement par la taxe de 5 % non incluse dans notre calcul.

Pour les **jeux vidéo**, l'année manquante a été conservée telle quelle plutôt qu'inventée, et l'éditeur manquant remplacé par une valeur « inconnu » pour ne pas perdre ces lignes. Nous avons également vérifié avec NumPy que les ventes mondiales correspondaient bien à la somme des ventes par région, ce qui a confirmé la cohérence du dataset.

Partie 3 — Création de variables et premières analyses

Sur des données propres, nous avons pu créer de nouvelles variables utiles à l'analyse.

Sur le **Titanic**, nous avons calculé la taille de la famille à bord, un indicateur « voyage seul ou non », et une catégorie d'âge — enfant, adolescent, adulte, senior. Cela nous a permis de calculer les premiers taux de survie : le taux global, puis par sexe et par classe.

Sur les **ventes du supermarché**, nous avons calculé le chiffre d'affaires total, le chiffre d'affaires moyen par transaction, la quantité totale vendue, et identifié les transactions extrêmes. Nous avons ensuite comparé les trois agences entre elles sur leur nombre de transactions, leur chiffre d'affaires et leur note de satisfaction moyenne.

Sur les **jeux vidéo**, nous avons établi le classement des dix jeux les plus vendus au monde, ainsi que les plateformes, les éditeurs et les genres générant le plus de ventes.

Ces premières analyses posent les bases des observations plus poussées que nous allons vous présenter maintenant.

Partie 4 — Analyses avancées et conclusions

Dans cette dernière partie, nous avons croisé plusieurs variables entre elles et tiré nos conclusions.

Sur le **Titanic**, le croisement du sexe et de la classe est notre résultat le plus marquant : les femmes de première classe affichent le taux de survie le plus élevé, les hommes de troisième classe le plus faible. L'âge moyen des survivants, le rôle de la situation familiale et le prix du billet renforcent ce constat : le profil le plus favorisé est une femme voyageant en classe supérieure, en famille restreinte.

Sur les **ventes du supermarché**, l'analyse par catégorie de produit et par type de clientèle — membre ou client normal — nous a permis de formuler des recommandations commerciales concrètes : renforcer les catégories les plus rentables, et développer un programme de fidélité ciblé sur les clients non-membres à fort potentiel.

Sur les **jeux vidéo**, la comparaison géographique entre Amérique du Nord, Europe et Japon montre des marchés aux préférences très différentes, tandis que l'analyse temporelle révèle un pic d'activité durant les années 2000, porté par les grandes consoles de cette époque.

Pour conclure, ce projet nous a permis de mettre en pratique l'ensemble de la chaîne d'un travail de Data Analyst : explorer, nettoyer, transformer et analyser des données réelles avec NumPy et Pandas, sans recourir au Machine Learning, en justifiant systématiquement nos choix méthodologiques.

Merci pour votre attention, nous restons à votre disposition pour toute question.